

Detección de enfermedades en hojas de cultivos andinos mediante redes neuronales convolucionales (CNN)

DOCENTE: Americo Estrada Sanchez

PRESENTADO POR:

- Calderon Romero, Yersson
- Guevara Valdivia, Alejandro Humberto
- Ochoa Cutipa, Edwards Andree



Detección de enfermedades en hojas de cultivos andinos mediante redes neuronales convolucionales (CNN) en comunidades de Cusco.



PLANTEAMIENTO DEL PROBLEMA

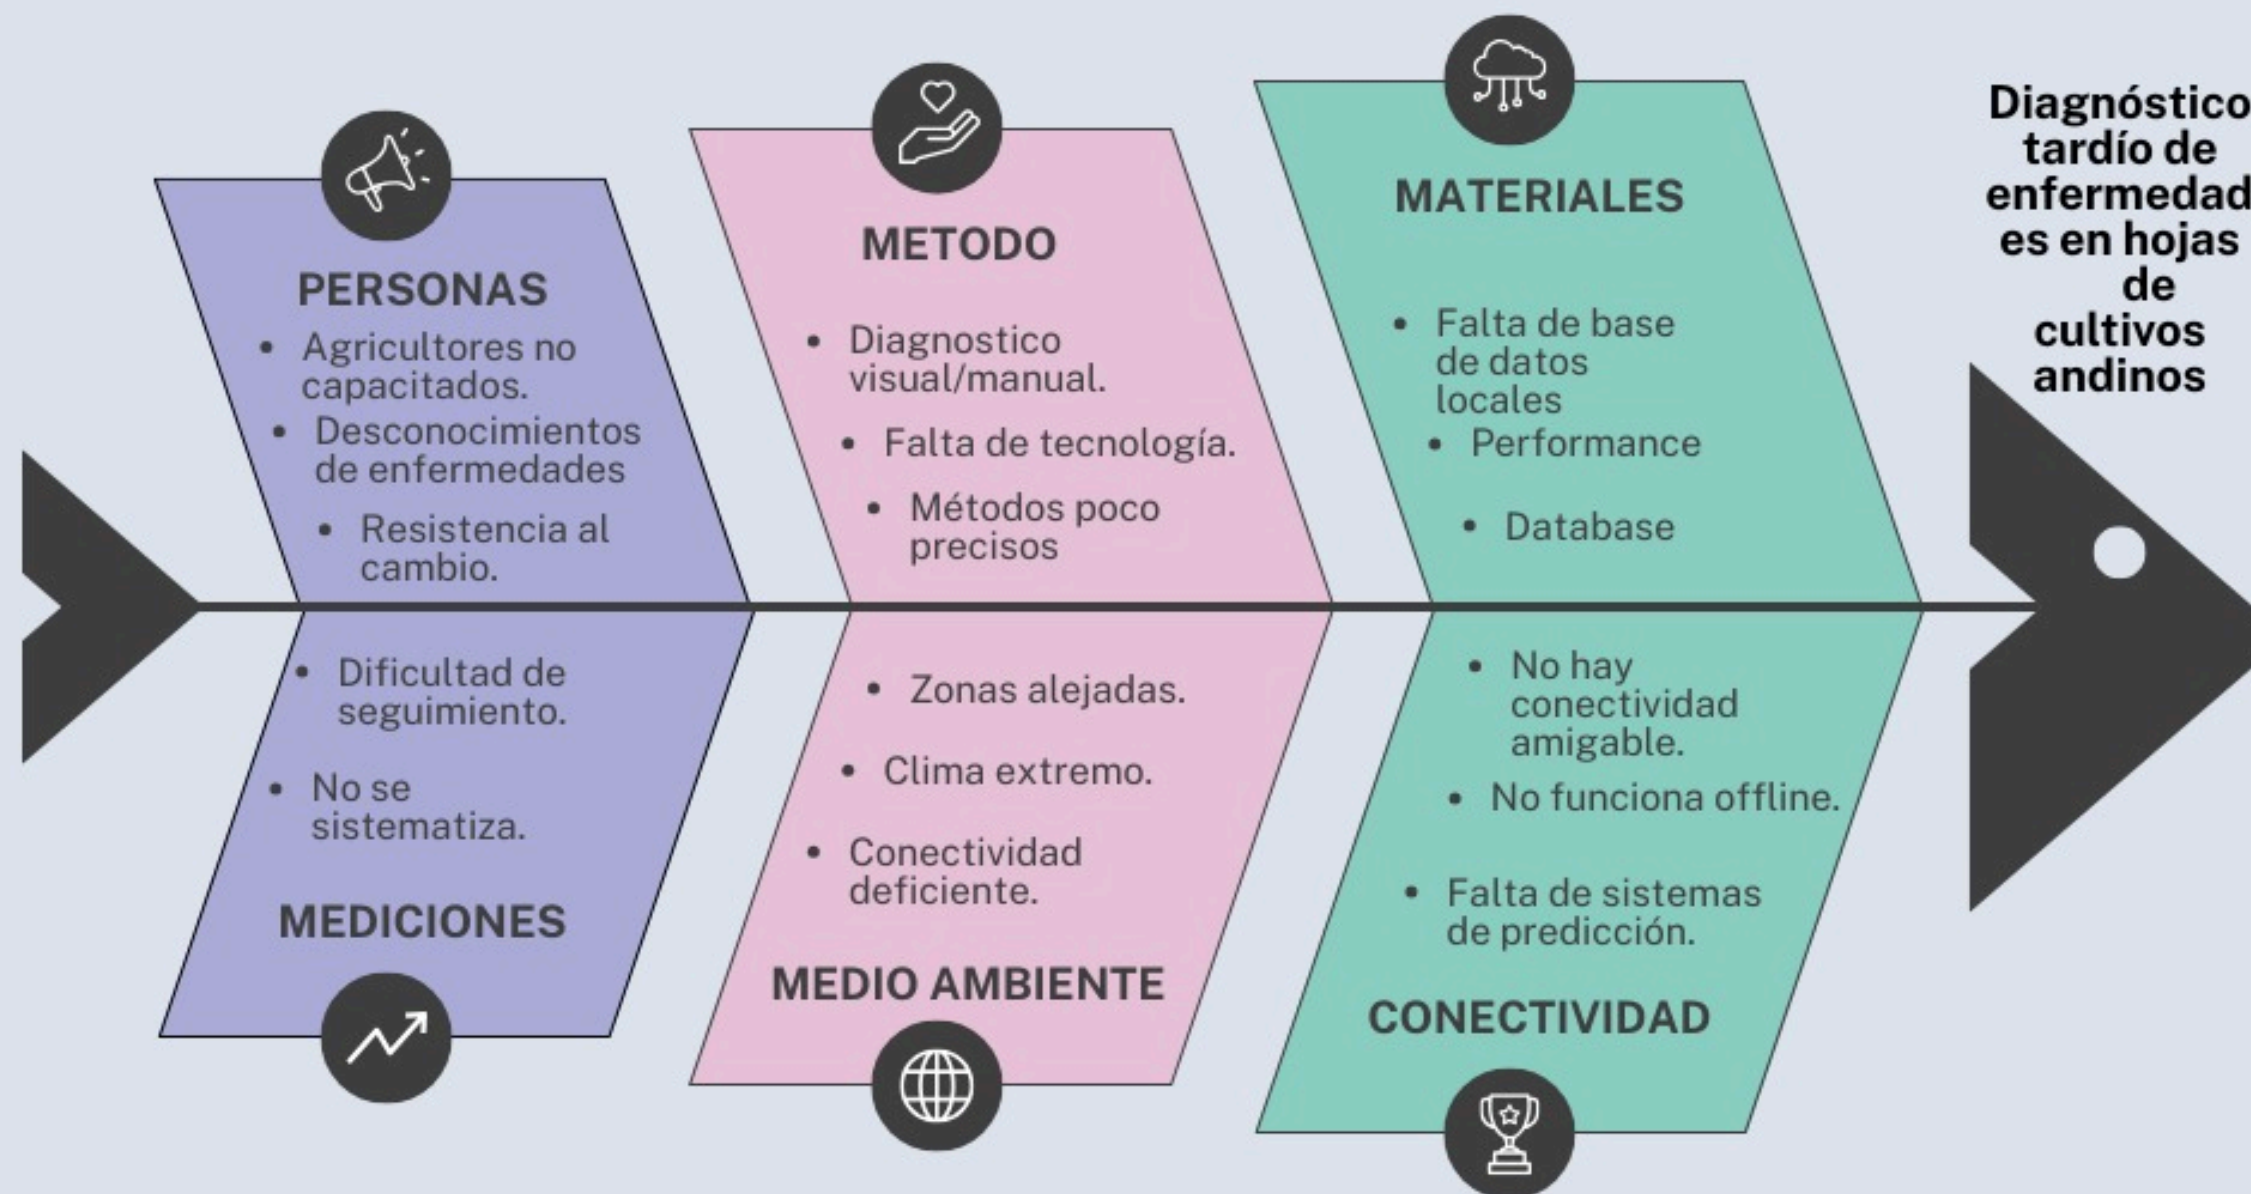
En comunidades agrícolas del Perú, los agricultores suelen tener dificultades para identificar tempranamente plagas o enfermedades en sus cultivos, especialmente en zonas rurales donde no siempre se cuenta con asistencia técnica. Estas enfermedades reducen el rendimiento de la producción agrícola, afectando la economía familiar y la seguridad alimentaria local.

De acuerdo con estudios recientes, la agricultura peruana pierde cerca del 40% de su producción anual debido a plagas y enfermedades, afectando principalmente cultivos como papa, maíz y quinua [1]. Investigaciones como las de Lozada-Portilla et al. (2025) evidencian que el uso de modelos híbridos basados en CNN permite detectar patologías en hojas de papa con alta precisión, superando el 90% de exactitud en entornos controlados [1].

Asimismo, Fernández Fernández y Pinglo Cabezas (2025) destacan el potencial del aprendizaje profundo en la detección automatizada de enfermedades del arroz, enfatizando su aporte en reducir tiempos de diagnóstico y dependencia del juicio humano [2].


Por tanto, se propone aplicar esta tecnología en los cultivos andinos del Perú, con el fin de generar un impacto directo en la sostenibilidad y productividad del sector agrícola.

DIAGRAMA DE ISHIKAWA BASADO EN ERRORES



OBJETIVO GENERAL

Desarrollar un modelo de red neuronal convolucional (CNN) entrenado con imágenes de hojas de cultivos andinos, capaz de detectar enfermedades de manera temprana, brindando información confiable al agricultor para la toma de decisiones.



OBJETIVO ESPECÍFICOS

01

Implementar un modelo CNN usando el framework PyTorch para la clasificación de enfermedades en hojas.

02

Entrenar el modelo con un dataset balanceado de 39 categorías que incluyen cultivos como papa, maíz y tomate.

03


Diseñar una interfaz web interactiva que permita subir imágenes y obtener el diagnóstico del estado de la hoja.

04

Evaluar el desempeño del modelo utilizando métricas de precisión, recall y F1-score.

HIPÓTESIS GENERAL

HG: El uso de una red neuronal convolucional (CNN) entrenada con imágenes de hojas de cultivos andinos permitirá detectar enfermedades de manera temprana con una precisión superior al 85%, proporcionando información confiable para la toma de decisiones agrícolas.



HIPÓTESIS ESPECÍFICAS

01

La implementación de un modelo CNN en el framework PyTorch permitirá clasificar correctamente las enfermedades foliares de los cultivos andinos, optimizando el proceso de diagnóstico agrícola.

02

Un modelo CNN entrenado con un dataset balanceado y diversificado en 39 categorías mejorará la capacidad de generalización del sistema, reduciendo los falsos positivos y negativos en la detección de enfermedades.

03

La incorporación de una interfaz web interactiva permitirá que los agricultores identifiquen el estado de salud de sus cultivos de forma accesible, práctica y en tiempo real, sin necesidad de conocimientos técnicos.

04

Si el modelo CNN alcanza valores de precisión, recall y F1-score superiores al 85%, se considerará que el sistema es viable para el diagnóstico automatizado de enfermedades foliares en cultivos andinos.

JUSTIFICACION E IMPORTANCIA

El uso de inteligencia artificial en la agricultura representa una oportunidad de innovación y sostenibilidad para comunidades rurales. Según FLYPIX.AI (2024), los sistemas de visión por computadora permiten identificar signos de enfermedades en etapas tempranas, reduciendo significativamente las pérdidas [4].

De manera complementaria, la Universidad de los Andes (2024) demuestra que los sistemas de visión artificial aplicados a cultivos pueden mejorar la monitorización y gestión de plantaciones, optimizando los recursos hídricos y fitosanitarios [5].

Además, desde un enfoque sociocultural, Flores Mendoza y Mejía Carhuajulca (2024) resaltan la importancia de adaptar las nuevas tecnologías al contexto andino, integrando la sabiduría agrícola tradicional con herramientas digitales [9].

Esta propuesta, por tanto, no solo aborda un problema técnico, sino también un desafío social y ambiental, alineado con los Objetivos de Desarrollo Sostenible (ODS 2: Hambre Cero y ODS 12: Producción y Consumo Responsables).




DESCRIPCIÓN DE LA SOLUCIÓN PROPUESTA

Se propone implementar un sistema de visión por computadora con redes neuronales convolucionales (CNN) que permita diagnosticar de manera temprana enfermedades en hojas de cultivos clave como papa, maíz y tomate.

EL SISTEMA PERMITIRÁ A LOS AGRICULTORES:

- Capturar o subir una foto de la hoja.
- Analizar la imagen mediante un modelo CNN entrenado.
- Obtener un diagnóstico preliminar con precisión superior al 85 %.
- Recibir recomendaciones iniciales para el manejo de la enfermedad detectada.

El enfoque inicial será sobre cultivos andinos de alta relevancia económica, con la posibilidad de ampliar progresivamente a otros como uva, fresa o pimiento.



ESTIMACIÓN DE TIEMPOS

1. Estimación inicial:

- Estimación total (suma de todas las historias de usuario): 256 horas.
- Este total representa el esfuerzo combinado del equipo, ya distribuido entre las 30 historias.

2. Capacidad del Equipo por Semana:

Los integrantes indicaron su disponibilidad diaria:

- Alejandro: 2.5 horas/día
- André: 2.0 horas/día
- Yersson: 4.0 horas/día

Promedio por persona (día):

$$\text{Promedio} = \frac{2.5 + 2.0 + 4.0}{3} = \frac{8.5}{3} = 2.83 \text{ horas/día (aprox.)}$$

Capacidad semanal por persona (7 días):

$$2.83 \text{ h/día} \times 7 \text{ días} = 19.83 \text{ h/semana/persona}$$

Capacidad total del equipo por semana (3 integrantes):

$$19.83 \times 3 = 59.50 \text{ h/semana (equipo)}$$

3. Verificación para ≤ 10 Semanas:

- Total, de horas requeridas: 256 h
- Capacidad total del equipo en 10 semanas:

Resultado: La capacidad disponible (595 h) es ampliamente superior a las 256 h requeridas. El equipo tiene holgura para completar el proyecto dentro de 10 semanas y absorber imprevistos, pruebas adicionales o correcciones.

4. Distribución del Trabajo:

Horas por semana requeridas (equipo):

$$\frac{256}{10} = 25.60 \text{ h/semana (equipo)}$$

Horas por persona por semana:


$$\frac{25.60}{3} = 8.53 \text{ h/semana/persona (aprox.)}$$

Horas por persona por día (7 días):

$$\frac{8.53}{7} = 1.22 \text{ h/día/persona (aprox.)}$$

CRONOGRAMA: DIAGRAMA DE GANTT

| Nombre Actividad | Actividades | Inicio | Días | Final | Épicas/HU |
|---------------------------------|--|------------|------|------------|--|
| Preparación & Configuración | Configuración del entorno; Recolección y organización del dataset; Preprocesamiento de imágenes; Diseño de la CNN base | 01/09/2025 | 7 | 07/09/2025 | Épica 1 (HU-1 a HU-4) |
| Funcionalidades Básicas | Clasificación sana/enferma; Detección de cultivo; Diagnóstico específico; Nivel de confianza; Interfaz web; Subida de imágenes | 08/09/2025 | 7 | 14/09/2025 | Épica 2 (HU-5 a HU-10) |
| Optimización Inicial del Modelo | Entrenamiento con dataset ampliado; Transfer learning; Métricas de validación; Gráficos de métricas; Optimización para web; Validación externa | 15/09/2025 | 7 | 21/09/2025 | Épica 3 (HU-11 a HU-13, HU-23, HU-25, HU-27) |
| Experiencia de Usuario I | Historial de diagnósticos; Ejemplos visuales; Recomendaciones básicas | 22/09/2025 | 7 | 28/09/2025 | Épica 4 (HU-14, HU-15, HU-16) |
| Experiencia de Usuario II | Clasificación de severidad; Validación de calidad de imagen; Notas en diagnósticos; Alertas tempranas | 29/09/2025 | 7 | 05/10/2025 | Épica 4 (HU-17, HU-18, HU-24, HU-26) |
| Reportes y Exportaciones | Reportes PDF; Exportación de datos anonimizados; Soporte multilenguaje; Retroalimentación; Manual de usuario | 06/10/2025 | 7 | 12/10/2025 | Épica 5 (HU-19 a HU-22, HU-30) |
| Mantenimiento y Documentación | Backup automático del modelo; Documentación técnica | 13/10/2025 | 7 | 19/10/2025 | Épica 6 (HU-28, HU-29) |



DEFINICIÓN DE SPRINTS

Capacidad real del sprint (equipo)

·Promedio diario por persona: 2.83 h/día

·Días del sprint: 7 días

·Horas disponibles por persona/sprint:

$2.83 \times 7 = 19.81h$

·Equipo de 3 personas:

$19.81 \times 3 = 59.43h/sprint$

Cada sprint tiene una capacidad de ~59 horas.

Total de esfuerzo a cubrir

·Total del backlog: 256 h

·Número de sprints necesarios:

$256/59.43 \approx 4.3$

Se necesitarán 5 sprints (los últimos con menos carga).

Asignación de historias de usuario a cada sprint

Agruparemos HU en orden de prioridad (alta → media → baja) hasta llenar ~59h por sprint.

Sprint 1 (59h máx – Total: 56h)

Enfoque: Preparación técnica y base del sistema.

·HU-1: Configuración del entorno (8h)

·HU-2: Recolección y organización del dataset (12h)

·HU-3: Preprocesamiento de imágenes (8h)

·HU-4: Diseño de arquitectura base CNN (12h)

·HU-5: Clasificación básica (8h)

·HU-8: Nivel de confianza (4h)

Total Sprint 1 = 56h

Sprint 2 (59h máx – Total: 56h)

Enfoque: Funcionalidades principales en la interfaz web.

·HU-6: Detección de cultivo (12h)

·HU-7: Diagnóstico específico por enfermedad (16h)

·HU-9: Interfaz web (12h)

·HU-10: Subida intuitiva de imágenes (4h)

·HU-16: Recomendaciones básicas (8h)

·HU-15: Ejemplos visuales (4h)

Total Sprint 2 = 56h

Sprint 4 (59h máx – Total: 52h)

Enfoque: Funcionalidades de usuario y reportes básicos.

·HU-14: Historial de diagnósticos (8h)

·HU-17: Clasificación de severidad (8h)

·HU-18: Validación de calidad de imagen (8h)

·HU-24: Notas en diagnóstico (4h)

·HU-26: Alertas tempranas (8h)

·HU-19: Reportes PDF (8h)

·HU-22: Retroalimentación (4h)

·HU-28: Backup automático del modelo (4h)

Total Sprint 4 = 52h

Sprint 3 (59h máx – Total: 60h)

Enfoque: Optimización y validación del modelo.

·HU-12: Transfer learning (16h)

·HU-13: Métricas de validación (8h)

·HU-23: Gráficos de métricas (8h)

·HU-25: Optimización del modelo para web (12h)

·HU-27: Validación con dataset externo (8h)

·HU-11: Dataset ampliado (8h)

Total Sprint 3 = 60h

Sprint 5 (59h máx – Total: 32h)

Enfoque: Inclusión, documentación y cierre del proyecto.

· HU-20: Exportación de datos anonimizados (8h)

· HU-21: Multilenguaje (8h)

· HU-30: Manual de usuario (8h)

· HU-29: Documentación técnica (12h)

Total Sprint 5 = 32h

The image features decorative geometric shapes in the corners. The top-left corner has three overlapping shapes: a yellow one on top, a red one in the middle, and a dark blue one at the bottom. The bottom-left corner has three overlapping shapes: a yellow one on top, a red one in the middle, and a dark blue one at the bottom.

GRACIAS...